

Evaluación Parcial 5

Aprendizaje no supervisado

Encargo | Estudiante

Subdirección de Diseño Curricular e Instruccional
2025

MALETA DIDÁCTICA DuocUC

Evaluación Parcial N°5

Aprendizaje no supervisado

Encargo | Estudiante

Sigla	Nombre Asignatura	Tiempo Asignado	% Ponderación
TLY1101	**Machine Learning**	**5 horas pedagógicas**	**20%**

1. Instrucciones generales Evaluación Parcial

Descripción

- La Evaluación Parcial 5 corresponde a la tercera entrega del proyecto semestral, y consiste en un informe técnico en formato Jupiter-Notebook. Los/las estudiantes aplican técnicas de Reducción de Dimensionalidad y Agrupamiento (Clustering) al conjunto de datos del proyecto, con el fin de descubrir patrones ocultos, segmentar la información y generar nuevo conocimiento útil para la toma de decisiones.
- Esta evaluación medirá los siguientes Indicadores de Logro:
  - IL3.1 Aplica técnicas de reducción de dimensionalidad, empleando algoritmos lineales, no lineales y de selección de variables, en un conjunto de datos para proyectos empresariales o de investigación.
  - IL3.2 Utiliza métodos de agrupamiento de datos utilizando algoritmos jerárquicos, basados en densidad y particionamiento, en el contexto de la segmentación de clientes, patrones o comportamientos organizacionales.
  - IL3.3 Diagnostica la calidad de los agrupamientos generados utilizando índices de validación interna y externa en el contexto de la generación de nuevo conocimiento a partir de datos organizacionales o de investigación.
- Es responsabilidad de cada equipo desarrollar el encargo en su tiempo de trabajo autónomo.

Ítem I: Instrucciones específicas de la Evaluación:

El informe técnico debe incluir los siguientes aspectos aplicados al caso:

1. Reducción de Dimensionalidad
    a. Selección de características: Aplique métodos de selección de características para filtrar las variables que no aportan información relevante. Explicite qué variables se conservan y cuáles se descartan (IE2)
    b. Reducción de Dimensionalidad: Aplique dos algoritmos de reducción de dimensionalidad (uno lineal como PCA y otro no lineal como t-SNE o UMAP) sobre el conjunto de datos. Describa brevemente su resultado (IE1)
2. Modelamiento de Agrupamiento (Clustering)
    a. Aplique tres algoritmos de agrupamiento. Asegúrese de explorar y seleccionar adecuadamente los hiperparámetros (IE3)
    b. Para uno de los casos anteriores, describa qué representa cada grupo en el mundo real (por ejemplo: "El Grupo 0 corresponde a clientes jóvenes de alto riesgo"; "El Grupo 1 son transacciones de bajo monto") (IE4)
3. Validación y Análisis Crítico
    a. Utilice índices de validación interna para evaluar la calidad los agrupamientos generados, como *Silhouette Score* u otro (IE5)
    b. Juzgue la calidad del agrupamiento en base a los índices de evaluación obtenidos anteriormente (IE6)

Los **aspectos formales** son:

- El informe técnico debe presentarse en formato Jupyter Notebook (.ipynb) (IE7)
- Todas las celdas deben estar ejecutadas, libres de errores y ser reproducibles. El código se debe poder ejecutar paso a paso cubriendo
- cada uno de los puntos solicitados. Por lo que no se aceptara en envío de la solución como un solo gran programa.
- Uso de Markdown para títulos, explicaciones teóricas, justificaciones y conclusiones parciales entre bloques de código.

Los **materiales, herramientas o insumos** que se **requieren para realizar esta** evaluación:

- Cada grupo desarrolla el encargo en su tiempo tiempo de trabajo autónomo, y para ello debe contar con un computador personal con google chrome con acceso a internet y a google colab.

Indicaciones para el Uso de Inteligencia Artificial (IA):

- **Uso ético y responsable:** Los estudiantes pueden utilizar la IA como apoyo para mejorar redacción, buscar referencias o crear diagramas, pero todas las ideas, análisis y justificaciones técnicas deben ser propias del equipo. Se debe declarar en el informe qué herramientas de IA se usaron y cómo se aplicaron.
- **Validación de Contenidos:** Todo contenido generado con IA debe ser revisado y validado por los estudiantes, asegurando que sea coherente con los requerimientos del proyecto.
- Todo uso de IA debe ser citado. https://bibliotecas.duoc.cl/ia
- Cualquier falta será revisada en relación con el reglamento académico y de evaluación

Aprendizaje No Supervisado

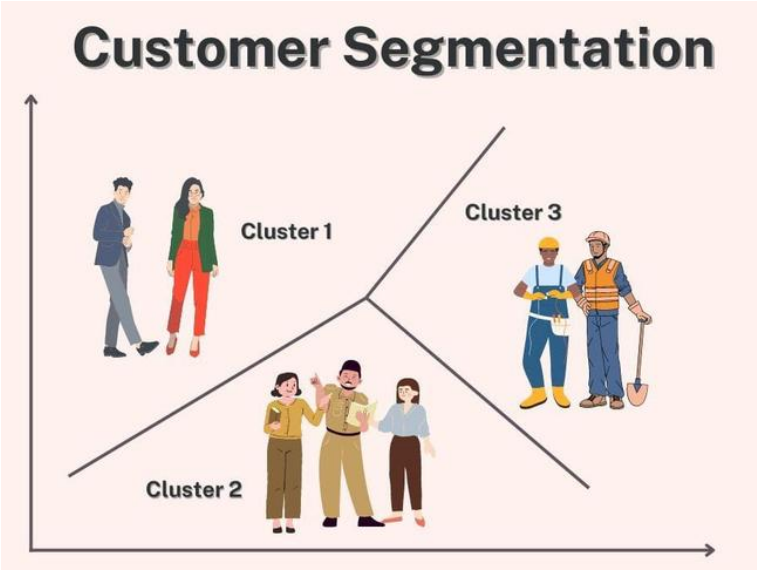
CASO: Análisis de la Personalidad de los Clientes

Introducción

El análisis de la personalidad de los clientes permite segmentarlos de tal modo que se pueda dividir a tus clientes en subgrupos basados en características comunes, como la edad, los ingresos, la ubicación, etc. ¿Por qué hacerlo? Porque te permite adaptar tus esfuerzos de marketing al perfil de tu cliente ideal.

Por ejemplo, un cliente que compra en una tienda de productos orgánicos probablemente tenga un salario elevado, se preocupe por su salud y muestre interés por la alimentación saludable y el ejercicio. En lugar de malgastar el presupuesto en campañas genéricas, concentra tus esfuerzos de marketing en campañas que se dirijan específicamente al segmento de mercado objetivo.

Lo anterior supone efectuar un análisis detallado de los clientes considerados como ideales para la empresa. Esto ayuda a una empresa a comprender mejor a sus clientes y le facilita la adaptación de sus productos a las necesidades, comportamientos e inquietudes específicos de los distintos tipos de clientes.



El análisis de la personalidad del cliente y su segmentación permite a una empresa ajustar su producto en función de los perfiles de sus clientes objetivo, pertenecientes a diversos segmentos. Por ejemplo, en lugar de invertir recursos en promocionar un nuevo producto ante todos los clientes registrados en su base de datos, la empresa puede identificar qué segmento tiene mayor probabilidad de adquirirlo y dirigir sus esfuerzos de marketing exclusivamente a dicho segmento.

Contexto

Una empresa de retail (venta al detalle) está interesada en efectuar un análisis exhaustivo de sus clientes, con el objetivo de segmentarlos y ofrecer productos y servicios dirigidos a cada segmento. El objetivo central de este esfuerzo es proporcionar a la empresa el perfil de cada grupo de clientes que logre identificar, con el fin de dirigir las campañas de venta en forma asertiva.

El dataset, de nombre ***"campana_marketing.csv"***, que acompaña a este caso, contiene información de las conductas de compra de los clientes que atiende la empresa e interesa sementar a los clientes en base a las conductas de compra. La idea identificar los grupos de clientes que pueda haber y analizar cada uno de esos grupos con el fin de dirigir campañas de marketing diferenciada a objeto de colocar, en forma exitosa, las ofertas que se les hagan.

Las características o variables del dataset se detallan a continuación:

Nro	Campo	Descripción
1	Educacion	Tipo de Educación
2	Ingresos_Anuales	Ingresos anuales del cliente
3	CantNinnos	Cantidad de niños en el hogar
4	CantAdolescentes	Cantidad de adolescentes en el hogar
5	DiasUltCompra	Días transcurridos desde la ultima compra
6	MontoVinos	Monto invertido en vinos en los últimos dos años
7	MontoFrutas	Monto invertido en frutas en los últimos dos años
8	MontoProductosCarneos	Monto invertido en productos cárneos en los últimos dos años
9	MontoProductosPescados	Monto invertido en pescados en los últimos dos años
10	MontoProductosDulces	Monto invertido en productos dulces en los últimos dos años

11	MontoProductosSelectos	Monto invertido en productos selectos en los últimos dos años
12	NroComprasDesc	Número de compras con descuento
13	NroTransacComprasWeb	Número de transacciones por compras vía Web
14	NroComprasCatalogo	Número de Compras por catálogo
15	CantComprasEnTienda	Cantidad de compras en tienda
16	NroVisitasWebMensual	Número de visitas realizadas vía Web en el último mes
17	AceptacionCampana3	Indicador binario que indica si el cliente acepto o no la oferta ofrecida por la campaña 3 (Si = 1, No = 0)
18	AceptacionCampana4	Indicador binario que indica si el cliente acepto o no la oferta ofrecida por la campaña 4 (Si = 1, No = 0)
19	AceptacionCampana5	Indicador binario que indica si el cliente acepto o no la oferta ofrecida por la campaña 5 (Si = 1, No = 0)
20	AceptacionCampana1	Indicador binario que indica si el cliente acepto o no la oferta ofrecida por la campaña 1 (Si = 1, No = 0)
21	AceptacionCampana2	Indicador binario que indica si el cliente acepto o no la oferta ofrecida por la campaña 2 (Si = 1, No = 0)
22	NroQuejas	Si el cliente ha presentado quejas en los ultimos dos años (Si = 1, No = 0).
23	Respuesta	Si el cliente acepto la campaña de marketing más reciente (Si = 1, No = 0).
24	Edad	La edad en años del cliente
25	Antiguedad	Antigüedad del cliente
26	Tamano_Familia	Cantidad de miembros de la familia del cliente
27	Solo	No vive solo = 0 Vive solo = 1

28	ConPareja	No vive con pareja = 0 Vive con pareja = 1
29	Suma_Montos_Compras	Suma de montos de compras.
30	Nro_Campanas_Aceptadas	Cantidad de campañas aceptadas.
31	Nro_Total_Compras	Total, de compras por Web, catalogo y por tienda.

Nota Importante: El dataset viene listo para ser procesado, por lo que no requiere: data cleaning, data scaling (normalizacion, estandarizacion).

Lo que se pide

1. Carga de datos y librerías

- Importe las librerías necesarias (pandas, numpy, scikit-learn, matplotlib, seaborn, umap-learn, etc.) y cargue el dataset **campana_marketing.csv.**

2. Reducción de Dimensionalidad y Análisis Exploratorio

- **PCA:**
  - Aplique PCA y obtenga los primeros ocho (8) componentes principales.
  - Muestre la varianza explicada (individual y acumulada) por cada uno de los 8 componentes.
  - Obtenga la matriz de cargas (*loadings*).
  - Identifique y presente las tres (3) variables originales con mayor peso en magnitud absoluta $|w|$ para cada componente.
  - Genere un mapa de calor (*heatmap*) que visualice las cargas de las variables en los componentes.
- **Proyección No Lineal (t-SNE):**
  - Aplique t-SNE fijando 2 componentes para proyectar y visualizar la distribución bidimensional de los datos originales.

3. Agrupamiento Particional y Jerárquico

- **Método del Codo (Elbow):**
  - Calcule la suma de errores al cuadrado (SSE/Inercia) para un rango de clústeres ($k = 1$ a 10).
  - Presente el gráfico de SSE vs. Número de clústeres (k).
- **Coeficiente Silhouette:**
  - Calcule el Coeficiente de Silhouette para el rango de clústeres analizado.
  - Presente el gráfico correspondiente de Silhouette vs. k.
- **K-Means:**
  - Determine el número óptimo de clústeres (k) basándose en los gráficos anteriores. En caso de discrepancia entre el Método del Codo y Silhouette, seleccione el valor mayor entre ambos.
  - Aplique K-Means con el k seleccionado y visualice los agrupamientos en un gráfico 2D (utilizando las dos primeras componentes principales o variables representativas).

- **Clusterización Jerárquica:**
  - Aplique el método jerárquico aglomerativo utilizando el enlace de Ward **(method='ward').**
  - Grafique el dendrograma resultante, trace una línea horizontal de corte y responda: ¿Cuántos clústeres se identifican según la altura de corte elegida?

4. Agrupamiento Basado en Densidad (DBSCAN)

- Aplique el algoritmo DBSCAN utilizando los parámetros: **epsilon = 0.2 y min_samples = 9.**
- Visualice la asignación de clústeres y puntos de ruido (*outliers*).
- Responda: ¿Identifican Elbow y Silhouette y DBSCAN la misma cantidad de clústeres? Justifique su respuesta considerando la naturaleza teórica de cada método.

5. Reducción de Dimensionalidad y Agrupamiento con UMAP

- Excluya la variable Respuesta.
- Aplique el algoritmo UMAP con los siguientes parámetros:
  - n_neighbors = 40
  - min_dist = 0.0
  - n_components = 2
  - random_state = 42
- Alimente el algoritmo K-Means utilizando las coordenadas obtenidas por UMAP y el número de clústeres (k) determinado en el paso 3.
- Presente la representación gráfica 2D con la segmentación resultante.

6. Perfilación e Interpretación de Clústeres mediante Árbol de Decisión

- Con las etiquetas obtenidas del agrupamiento óptimo, entrenar un modelo de **Árbol de Decisión (DecisionTreeClassifier)** utilizando todas las características/variables de los sujetos y las etiquetas del clúster como variable objetivo (*target*).
- **Importancia de características (*Feature Importance*):** Calcular y graficar la importancia relativa de cada variable en la división de los clústeres para identificar cuáles son los factores determinantes que separan a los grupos.
- **Reglas de corte (*Decision Tree Structure*):** Exportar o visualizar los primeros niveles del árbol (por ejemplo, con profundidad max_depth=3 o 4) para interpretar las reglas lógicas principales que definen a cada segmento de la población.

7. Perfilación de Clústeres

Desarrolla el código necesario para cumplir las siguientes directrices:

- Agrupación y Consolidación: Añade la etiqueta de clúster generada por K-Means (clusters_kmeans) a dataset y agrupa la información.
- Cálculo de Métricas Descriptivas: Obtén el promedio (o mediana) de las 3 características más determinantes identificadas por el árbol para cada uno de los clústeres.
- Visualización de Soporte: Genera un mapa de calor (Heatmap) que condense estos promedios por clúster para facilitar su lectura rápida.
- Análisis Crítico: Redacta una breve conclusión (máximo 1 párrafo por clúster) traduciendo estas métricas a perfiles de negocio reales. *Ejemplo: "El Clúster X está compuesto por personas que viven solas y tienen un nivel de consumo medio-alto..."*

A Entregar:

- Archivo Notebook, con extensión. ipynb en ***Python***, que contenga la solución paso a paso. En el archivo Notebook debe estar anotado, al principio el nombre de los integrantes del equipo.

Envío

Envíe todo su desarrollo al Blackboard (vía mensaje, en formato RAR) y COMO RESPALDO al correo: f.madridp@profesor.duoc.cl, con asunto TLY_TE3_numero de sección. Su envío debe estar dentro de la hora asignada al desarrollo del esfuerzo.

Nombre el Archivo a enviar:

TLY_TE3_NroSección_PrimeraLetraNombreIntegrante1Apelllido_PrimeraLetraNombreIntegrante2Apelllido_
PrimeraLetraNombreIntegrante3Apelllido

Ejemplo: Si el grupo es de la sección 002D y está compuesto por Carlos Cárdenas, Julio Saldivia y Heriberto Valenzuela, el nombre del archivo debe ser:

TLY_TE3_002D_CCardenas_JSaldivia_HValenzuela

ATENCIÓN: NO SE ACEPTARÁ LA ENTREGA DE INFORMES POR MEDIO DE HACER REFERENCIAS A LINKS O DRIVE COMPARTIDO.

REVISE BIEN EL ENVIO QUE HAGA, PUES EN BASE A ESE SE APLICARA LA CORRECCION.

NO SE ACEPTARÁN ENVIOS POSTERIORES.

2. Pauta de Evaluación (Escala de valoración)

Categoría	% logro	Descripción niveles de logro
Muy buen desempeño	**100%**	Demuestra un desempeño destacado, evidenciando el logro de todos los aspectos evaluados en el indicador.
Buen desempeño	**80%**	Demuestra un alto desempeño del indicador, presentando pequeñas omisiones, dificultades y/o errores.
Desempeño aceptable	**60%**	Demuestra un desempeño competente, evidenciando el logro de los elementos básicos del indicador, pero con omisiones, dificultades o errores.
Desempeño incipiente	**30%**	Presenta importantes omisiones, dificultades o errores en el desempeño, que no permiten evidenciar los elementos básicos del logro del indicador, por lo que no puede ser considerado competente.
Desempeño no logrado	**0%**	Presenta ausencia o incorrecto desempeño.

Indicador de Evaluación	Categorías de Respuesta					Ponderación Indicador de Evaluación
	Muy buen desempeño	Buen desempeño	Desempeño aceptable	Desempeño incipiente	Desempeño no logrado	
	100%	80%	60%	30%	0%	
IE1 Implementa ***algoritmos de reducción de dimensionalidad*** adecuados a la estructura de los datos, en el contexto del análisis de datos del proyecto.						15%
IE2 Aplica ***métodos de selección de variables*** para identificar y conservar las características más relevantes en el contexto de la optimización del conjunto de datos del proyecto.						15%
IE3 Aplica ***modelos de aprendizaje no supervisado*** mediante algoritmos de segmentación según corresponda						15%
IE4 ***Interpreta los resultados del agrupamiento identificando patrones o comportamientos relevantes***, en el contexto de la generación de conocimiento a partir de los datos del proyecto.						15%
IE5 ***Reconoce métricas de rendimiento*** para modelos no supervisados que permitan validar los resultados obtenidos.						15%
IE6 ***Juzga la calidad de los agrupamientos*** resultantes a partir de la validación interna y/o externa de los resultados.						15%
IE7 Elabora un informe técnico del proyecto en formato Jupyter Notebook estructurado y sin faltas de ortografía ni de redacción.						10%
					Total	100%